Diplomatura en Ciencia de Datos y Análisis Avanzado

Trabajo final integrador

Octubre 2026

PREDICCIÓN DE DESECHOS DE COMIDA EN LOCALES COMERCIALES

Integrantes:

- Antonella Boris Pringles
- Daniel Linares
- Elian Andrés Pellegrino
- Jaime Enrique Mora
- Manuel Perez

Resumen Ejecutivo

Este trabajo analiza el uso de herramientas de Machine Learning para reducir el desperdicio de alimentos durante su comercialización. Según la ONU, gran parte de las pérdidas ocurre en comercios y servicios alimentarios, principalmente por sobrestock y baja rotación de productos.

El objetivo fue predecir la cantidad de alimentos desperdiciados, identificar los tipos de negocios con mayores pérdidas y determinar las variables que más influyen en este fenómeno. Se planteó como hipótesis que la demanda, el tipo de alimento y su valor de venta están relacionados con el nivel de desperdicio.

Los resultados mostraron que Random Forest fue el modelo más preciso para estimar desperdicios, mientras que la Regresión Logística destacó en la identificación de casos con pérdidas. Estos hallazgos demuestran que las técnicas de Machine Learning pueden apoyar la gestión de inventarios, reducir el sobrestock y disminuir el desperdicio alimentario.

Definición del Problema y Relevancia

Se desarrollaron modelos de Machine Learning para predecir el desperdicio alimentario en comercios. Los modelos de regresión estimaron la cantidad de desperdicio generada, mientras que la Regresión Logística permitió identificar si existiría o no desperdicio.

Para el entrenamiento se utilizaron variables habituales en la gestión de inventarios, como demanda esperada, cantidad comprada, vida útil de los productos y condiciones climáticas.

El objetivo fue anticipar tanto la ocurrencia como la magnitud del desperdicio con la mayor precisión posible. Dado que los datos reales suelen ser limitados y estar dispersos entre distintos negocios, se empleó un dataset sintético para el desarrollo y evaluación de los modelos.

Datos y Metodología

Se trabajó con una base de datos sintética realizada con IA, basada en datos reales de inventario y ventas de restaurantes, cafeterías, supermercados y cloud kitchens recolectados durante el año 2025 y publicada en la plataforma Kaggle.

A diferencia de los conjuntos de datos generados aleatoriamente, las variables se conectan de manera lógica para reflejar escenarios reales de gestión de inventario. Variables como la demanda de los clientes afectan las ventas, mientras que las promociones pueden incrementar el volumen comercializado.

También tiene en cuenta las condiciones climáticas, donde la lluvia afecta a las ventas. El inventario restante del día, su vida útil y la temperatura del almacenamiento, van a influir en la cantidad de desperdicio.

La base de datos contiene un total 16 columnas y 8.000 registros. Cada registro representa la situación de inventario de un negocio en una fecha determinada, que indica cuánto se compró a proveedores, cuánto se vendió, cuánto sobró y cuánto efectivamente se tiró de lo que sobró. A continuación, presentamos un resumen de las filas con las que trabajamos:

Columna	Tipo de datos	Descripción
Date	string (date, YYYY-MM-DD)	Fecha del registro de inventario. Abarca un año (del 1 de enero de 2025 al 31 de diciembre de 2025).
Business_Type	categorical	Tipo de negocio: Restaurante, Supermercado, Cafetería, Cocina fantasma.
Food_Category	categorical	Tipos de alimentos: Frutas, Verduras, Lácteos, Panadería, Carne, Comida preparada.
Shelf_Life_Days	float (integer-valued)	Número de días antes de la fecha de caducidad del lote, depende de la categoría de alimentos.
Purchase_Quantity	integer	Unidades totales compradas a proveedores y almacenadas del día (unidades).
Storage_Temperature	float	Temperatura de almacenamiento en grados Celsius, depende de la categoría de alimentos.
Daily_Demand	float (integer-valued)	Demanda estimada/realizada de los clientes del día (unidades), influenciada por el tipo de negocio, el clima y las promociones.
Promotion	binary (Yes/No)	Si hubo alguna promoción/descuento vigente ese día.
Weather	categorical	Condición climática: Soleado, Lluvioso, Nublado, Caluroso.
Waste_Quantity	integer	Unidades desperdiciadas del stock restante. Siempre <= Stock restante.

Para evitar data leakage, eliminamos varias columnas. Algunas como el número de inventario por ser información redundante, y otros datos que en la vida real no tendríamos disponibles antes de que se produzca el desperdicio de comida, como la cantidad de ventas, si se donó la comida o la razón del desperdicio.

Columna	Tipo de datos	Descripción
Inventory_ID	string	Identificador único para cada registro de inventario diario (p. ej., INV000001).
Units_Sold	integer	Unidades totales vendidas del día (unidades). Siempre <= Purchase_Quantity.
Remaining_Stock	integer	Unidades restantes tras la venta (Purchase_Quantity menos Units_Sold).
Waste_Reason	categorical	Causa principal del desperdicio: Caducidad, sobreproducción, baja demanda, problema de almacenamiento o ausencia de desperdicio (no se produjo ningún desperdicio).
Donation_Made	binary (Yes/No)	Si los alimentos desperdiciados pero aún aptos para el consumo fueron donados en lugar de desechados.
Waste_Level	categorical (target)	Gravedad general del desperdicio registrada: Baja, Media, Alta. Derivada de la relación desperdicio-compra.

Preparación de los datos

Antes de entrenar los modelos fue necesario realizar una etapa de preprocesamiento para garantizar la calidad y consistencia de los datos utilizados.

En primer lugar, se ordenaron los registros cronológicamente utilizando la fecha disponible en el conjunto de datos. Posteriormente, se dividió la información en tres conjuntos independientes: **Entrenamiento, Validación** y **Prueba**.

Esta división temporal permitió simular una situación real en la que los modelos deben predecir eventos futuros utilizando únicamente información histórica.

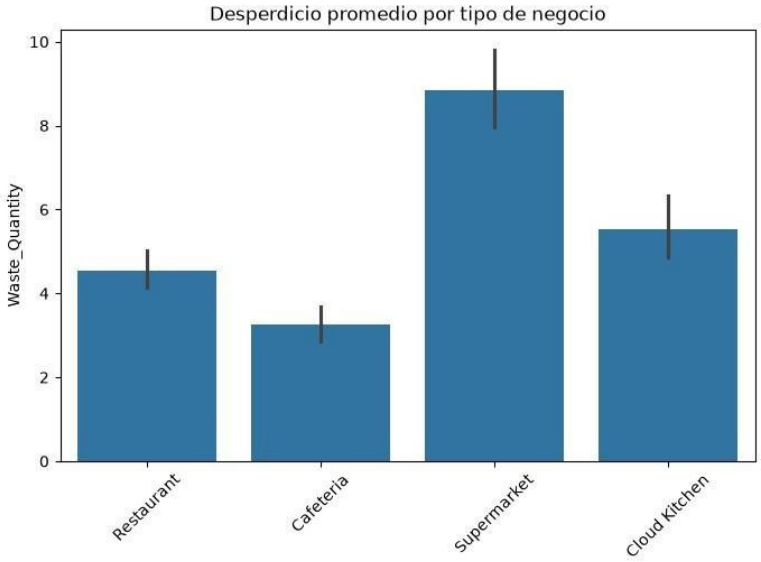
Esta estrategia también permitió evitar la fuga de información (data leakage), garantizando que las evaluaciones reflejaran de forma más realista el desempeño esperado de los modelos ante datos futuros.

Los valores faltantes fueron tratados mediante estrategias de imputación basadas en la mediana para las variables numéricas y en la moda para las categóricas. Asimismo, las variables numéricas fueron escaladas y las categóricas transformadas mediante técnicas de codificación adecuadas para su utilización en algoritmos de Machine Learning.

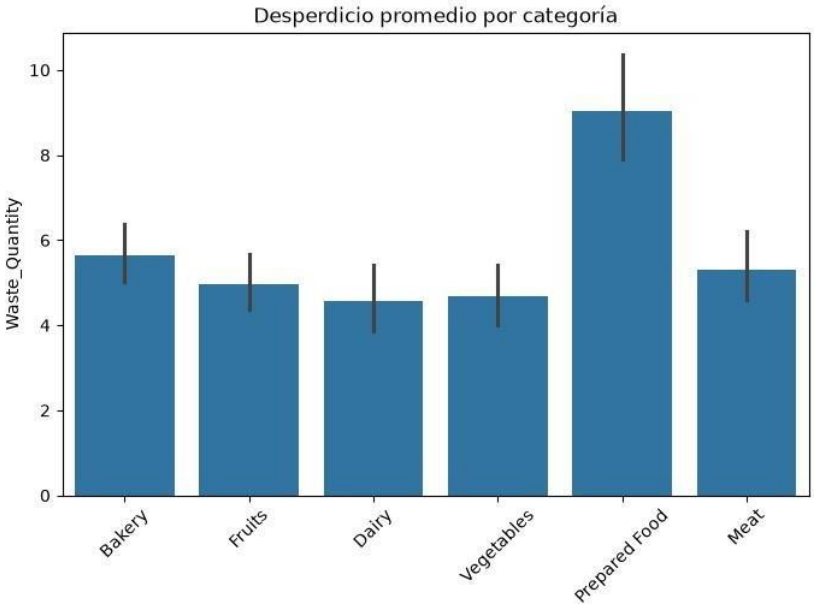
Análisis exploratorio (EDA)

El análisis exploratorio permitió comprender mejor la distribución del desperdicio y detectar patrones relevantes antes de construir los modelos predictivos.

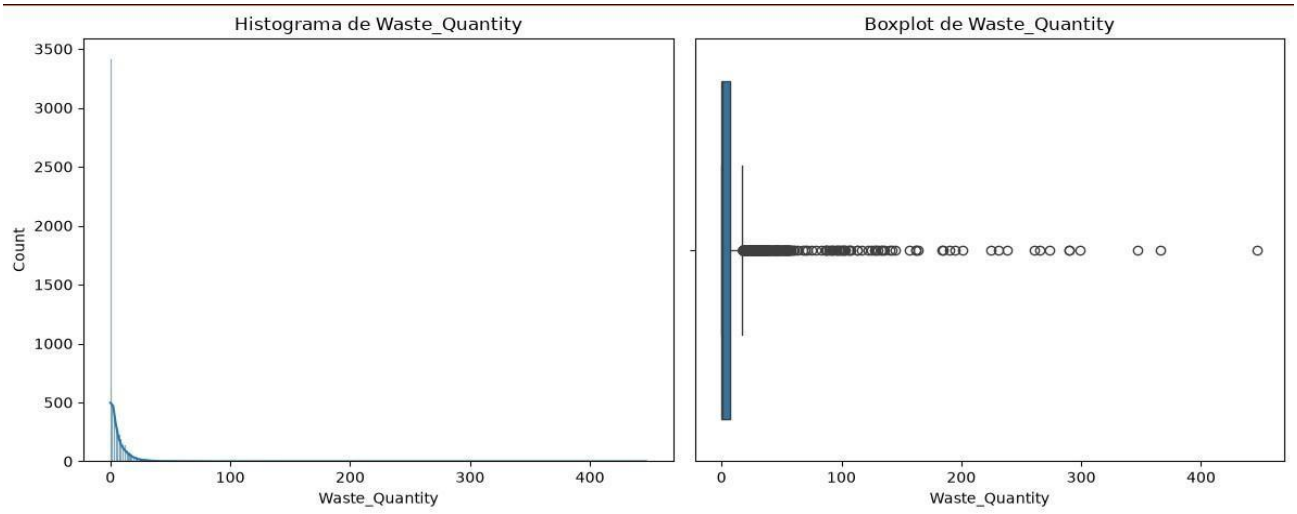
Los supermercados registran el mayor desperdicio promedio de alimentos, mientras que las cafeterías presentan el menor. Esto indica que el tipo de negocio puede influir en la cantidad de desperdicio generada.



Se observa que la categoría de **“Pepared Food (comida preparada)”** tiene el mayor desperdicio promedio mientras que **“Dairy (lácteos)”** tiene el menor desperdicio.



La mayor parte de los registros presenta cantidades bajas de desperdicio de alimentos. Sin embargo, existen varios valores atípicos elevados, lo que provoca que la distribución de **Waste_Quantity** esté sesgada hacia la derecha



También se identificaron valores extremos dentro de la variable **Waste_Quantity**. Estos casos fueron conservados en el análisis debido a que representan situaciones reales que pueden ocurrir en contextos comerciales.

En conjunto, el análisis exploratorio permitió identificar diferencias relevantes entre tipos de negocio y categorías de alimentos, además de confirmar la presencia de valores extremos que representan situaciones reales de desperdicio.

Relación entre los modelos desarrollados

El proyecto abordó el problema del desperdicio alimentario desde dos perspectivas complementarias.

Por un lado, se utilizaron modelos de regresión con el objetivo de estimar la cantidad exacta de desperdicio generado **(Waste_Quantity)**. Para ello se compararon una Regresión Lineal y un modelo Random Forest, evaluando cuál era capaz de representar mejor la relación entre las variables operativas y la cantidad desperdiciada. Por otro lado, se desarrolló una Regresión Logística, utilizada como modelo de clasificación, cuya finalidad consistió en determinar si existiría o no desperdicio **(Hubo_Desperdicio)**.

De esta manera, los modelos no compiten directamente entre sí, ya que responden preguntas distintas:

- **Regresión Logística:** ¿Habrá desperdicio?
- **Random Forest:** ¿Cuánto desperdicio habrá?
- **Regresión Lineal:** modelo de referencia utilizado para comparar el desempeño de Random Forest.

La combinación de ambos enfoques permite obtener una visión más completa del problema, ya que no sólo se puede anticipar la aparición del desperdicio, sino también estimar su magnitud.

Modelos desarrollados:

Con el objetivo de abordar el problema desde distintas perspectivas, se construyeron modelos tanto de regresión como de clasificación.

Modelos de regresión:

La regresión tuvo como finalidad predecir directamente la cantidad de desperdicio generada. Los algoritmos evaluados fueron:

- **Regresión Lineal**.
- **Random Forest.**

Modelo de clasificación:

Por otro lado, se desarrolló una **Regresión Logística** para predecir si se produciría o no desperdicio en cada observación.

Esta estrategia permitió abordar simultáneamente dos preguntas relevantes: **¿Habrá desperdicio? ¿Cuánto desperdicio habrá?**

La combinación de modelos de clasificación y regresión permitió obtener una visión más completa del problema, anticipando tanto la ocurrencia del desperdicio como su magnitud estimada.

Validación y comparación de modelos

Una vez entrenados los modelos, se realizó una evaluación utilizando exclusivamente el conjunto de validación.

La siguiente tabla resume los resultados obtenidos por cada modelo durante esta etapa:

Modelo	RMSE	MAE	R^2	Accuracy	F1 Score	ROC AUC
Regresión Lineal	6.15	4.20	86.00%	-	-	-
Random Forest	3.50	1.29	96.00%	-	-	-
Regresión Logística	-	-	-	95.20%	95.80%	0.984

La Regresión Lineal y Random Forest fueron comparados mediante **RMSE, MAE y R^2**. Los resultados evidenciaron una ventaja clara del modelo Random Forest, el cual logró reducir el error de predicción y explicar una mayor proporción de la variabilidad observada en los datos.

Por su parte, la Regresión Logística obtuvo valores elevados de **Accuracy, F1-Score y ROC AUC**, demostrando una capacidad significativa para identificar correctamente los casos donde existía desperdicio.

El modelo Random Forest fue seleccionado como la mejor alternativa para la predicción de cantidades desperdiciadas.

Además de presentar las mejores métricas de validación, se identificó una diferencia importante respecto a la Regresión Lineal.

Durante la validación:

- Regresión Lineal generó 393 predicciones negativas.
- Random Forest no generó predicciones negativas.

Este hallazgo resulta especialmente relevante porque una cantidad de desperdicio negativa carece de sentido desde el punto de vista operativo. Por lo tanto, además de obtener mejores métricas, Random Forest produjo resultados más consistentes y realistas.

En consecuencia, se decidió utilizar exclusivamente este modelo para la evaluación final sobre el conjunto de prueba.

Resultados finales

Luego de seleccionar el modelo ganador, se realizó una evaluación final utilizando el conjunto de prueba, compuesto por datos que nunca fueron utilizados durante el entrenamiento ni durante la validación.

Las métricas obtenidas fueron:

Métrica	Valor
RMSE Test	5.96
MAE Test	1.51
R^2 Test	0.88

Estos resultados indican que el modelo mantiene una capacidad de generalización adecuada y conserva un buen nivel de precisión cuando se enfrenta a nuevas observaciones. El valor de **R^2** obtenido indica que el modelo es capaz de explicar aproximadamente el 88% de la variabilidad observada en la cantidad de desperdicio, manteniendo un desempeño sólido sobre datos no utilizados durante el entrenamiento y la validación.

En términos prácticos, esto sugiere que el modelo podría utilizarse como herramienta de apoyo para anticipar desperdicios futuros dentro de contextos operativos similares.

Estos resultados confirman que el modelo mantiene un desempeño robusto sobre datos no utilizados durante el entrenamiento, lo que refuerza su potencial aplicación en entornos reales para apoyar la toma de decisiones relacionadas con la gestión del inventario y la reducción del desperdicio.

Variables más importantes e interpretación

Una de las ventajas de Random Forest es la posibilidad de analizar la importancia relativa de cada variable en el proceso de predicción.

Las variables con mayor importancia dentro del modelo fueron:

	Variable	Importancia (%)
0	num__Purchase_Quantity	79.75
3	num__Daily_Demand	9.43
2	num__Storage_Temperature	4.41
14	cat__Weather_Rainy	2.68
1	num__Shelf_Life_Days	1.84
6	cat__Business_Type_Supermarket	0.33
10	cat__Food_Category_Prepared Food	0.33
13	cat__Weather_Hot	0.24
11	cat__Food_Category_Vegetables	0.20
12	cat__Promotion_Yes	0.19
15	cat__Weather_Sunny	0.18
8	cat__Food_Category_Fruits	0.12
4	cat__Business_Type_Cloud Kitchen	0.09
7	cat__Food_Category_Dairy	0.08
9	cat__Food_Category_Meat	0.07
5	cat__Business_Type_Restaurant	0.06

Particularmente **“Purchase_Quantity (cantidad comprada)”** concentró aproximadamente el 80% de la importancia total. Esto sugiere que las decisiones de compra tienen una influencia determinante sobre el nivel de desperdicio generado.

La importancia de **“Daily_Demand (demanda diaria)”** indica que los errores en la estimación de ventas pueden generar excedentes de inventario que terminan siendo descartados.

Finalmente, variables como la temperatura de almacenamiento y las condiciones climáticas muestran que factores operativos y ambientales también influyen en la generación de desperdicios.

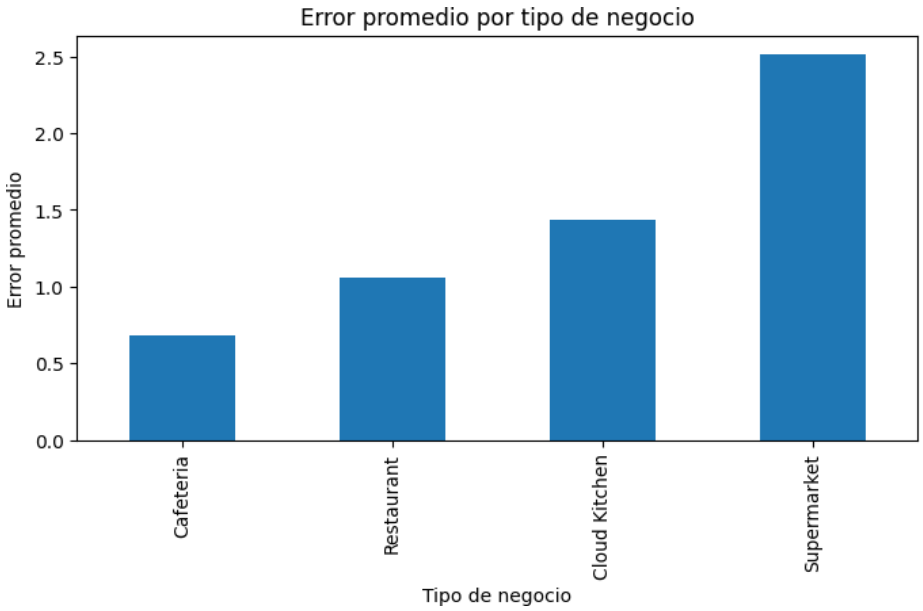
En conjunto, los resultados sugieren que la gestión de compras, la estimación de la demanda y las condiciones de almacenamiento son los principales factores asociados al desperdicio alimentario en este conjunto de datos.

Impacto económico potencial

Considerando un escenario hipotético donde cada unidad desperdiciada representa una pérdida de $10, una reducción de 100 unidades de desperdicio permitiría generar un ahorro aproximado de $1.000.

Dado que las variables más importantes del modelo fueron la cantidad comprada (***Purchase_Quantity***) y la demanda diaria (***Daily_Demand***), una mejor planificación de compras e inventario podría contribuir a disminuir el desperdicio y generar beneficios económicos concretos para el negocio.

Segmentación del desempeño del modelo



Se analizó el desempeño del modelo según el tipo de negocio mediante el error promedio de predicción.

Los resultados mostraron que las cafeterías presentaron el menor error promedio, mientras que los supermercados registraron el mayor error. Esto indica que la dificultad de predicción varía entre los distintos segmentos analizados y que el comportamiento del modelo no es exactamente uniforme en todos los contextos operativos.

A pesar de estas diferencias, el modelo mantuvo un desempeño satisfactorio en todos los tipos de negocio evaluados.

Conclusiones

El proyecto permitió demostrar que las técnicas de Machine Learning pueden utilizarse exitosamente para modelar y anticipar el desperdicio alimentario en locales comerciales.

Entre los principales hallazgos se destacan que Random Forest fue el modelo con mejor desempeño para la predicción de cantidades desperdiciadas, la Regresión Logística mostró una alta capacidad para detectar la ocurrencia de desperdicio, y la demanda esperada junto con las condiciones de almacenamiento presentaron una influencia significativa sobre el nivel de desperdicio generado. Además, se observó que el desempeño del modelo varía según el tipo de negocio analizado y que una mejor planificación de compras y demanda podría traducirse en beneficios económicos concretos.

A partir de estos resultados, se recomienda optimizar las cantidades adquiridas, mejorar los procesos de estimación de demanda, fortalecer los controles de almacenamiento e incorporar herramientas predictivas como apoyo a la toma de decisiones operativas.

Como conclusión general, los resultados sugieren que la reducción del desperdicio alimentario depende principalmente de una mejor planificación de compras y demanda, áreas donde los modelos desarrollados pueden aportar valor concreto a la gestión empresarial. Asimismo, los escenarios económicos analizados muestran que la utilización de herramientas predictivas puede contribuir a reducir pérdidas y apoyar la toma de decisiones operativas.